

## Auxiliar 4 - “Algoritmos en Memoria Secundaria”

Profesores: Pablo Barceló  
Gonzalo Navarro  
Auxiliar: ~~Manuel~~ Ariel Cáceres Reyes

9 de abril del 2018

### P1. Relación

Dada una relación binaria  $\mathcal{R} \subseteq \{1, \dots, k\} \times \{1, \dots, k\}$ , representada como un archivo secuencial de sus pares  $(i, j)$ , construya algoritmos eficientes (considerando que  $N \gg M$ ) para determinar si la relación es:

- a) Refleja
- b) Simétrica

### P2. Desordenar

Se nos pide desordenar un archivo ordenado de números reales. Teniendo una función `rand(t)` que nos da un entero aleatorio uniforme entre 1 y  $t$ , debemos leer un archivo de disco de largo  $N$  y producir otro de largo  $N$ , donde se encuentren los mismos elementos permutados. Su programa debe producir cualquier permutación con la misma probabilidad (para simplificar, no describa cómo permutar uniformemente en memoria interna).

- a) Resuelva el problema en  $\mathcal{O}(n)$  I/Os para el caso en que  $N \leq M^2/B$ .
- b) Resuelva el problema en el mismo tiempo de ordenar en disco, para el caso general.

### P3. Join y Split en B-tree

- a) La operación de `join` de B-trees toma como entrada dos B-trees  $T_1$  y  $T_2$ , y una llave  $x$  tal que toda llave en  $T_1$  es menor que  $x$  y toda llave en  $T_2$  es mayor que  $x$ , y entrega como resultado un B-tree contiene a  $x$  y a todas las llaves en  $T_1$  y en  $T_2$ .  
Explique cómo implementar la operación de `join` entre  $T_1$  y  $T_2$  utilizando a lo más  $\mathcal{O}(1 + |h(T_1) - h(T_2)|)$  accesos a memoria secundaria, donde  $h(T)$  representa la altura de la raíz de  $T$ .
- b) La operación de `split` de B-trees toma como entrada un B-tree  $T$ , y una llave  $x$  en  $T$ , y entrega como resultado dos B-trees  $T_1$  y  $T_2$  tal que  $T_1$  contiene todas las llaves en  $T$  que son estrictamente menores que  $x$  y  $T_2$  contiene todas las llaves en  $T$  que son estrictamente mayores que  $x$ .  
Explique cómo implementar esta operación con  $\mathcal{O}(B \cdot h(T))$  accesos a memoria secundaria.

“Someone is sitting in the shade today because someone planted a tree a long time ago.”  
Warren Buffett

## Soluciones

### **P1. Relación**

Para esta pregunta asumiremos que no se repiten pares.

- a) Basta tener un contador iniciado en 0, escanear todo el input bloque por bloque y cuando encontramos un par de la forma  $(i, i)$  aumentamos el contador. Cuando terminamos de escanear respondemos que la relación es refleja si el contador es igual a  $k$ , no en caso contrario. Como solo escaneamos el input una vez hacemos  $n = \frac{N}{B}$  llamadas a disco. ⚡
- b) Con el siguiente algoritmo:
- Hacer una copia de los pares, pero con sus coordenadas invertidas.  $\mathcal{O}(n)$ .
  - Ordenar tanto el original como la copia lexicográficamente (es decir, por la primera coordenada y en caso de empate mirar la segunda coordenada para decidir).  $\mathcal{O}(n \log_m n)$ , con  $m = \frac{M}{B}$ .
  - Comparar que tanto la copia como el original sean iguales.  $\mathcal{O}(n)$

Por lo tanto, el costo del algoritmo es  $\mathcal{O}(n \log_m n)$  llamadas a disco.

### **P2. Permutar**

- a) 1. Haremos operaciones sobre  $N/M$  archivos (las operaciones serán hechas con buffers de tamaño  $\leq B$  por lo que ocuparemos  $\leq BN/M \leq M$  memoria principal).
2. Al azar distribuimos uniformemente los elementos del input a los archivos ( $M$  elementos en cada archivo).
3. Por cada archivo: lo leemos, lo permutamos en memoria principal y lo volvemos a escribir a memoria secundaria.
4. Finalmente, vamos eligiendo al azar un archivo (dejamos de considerarlos si quedan vacíos) y sacamos el primer elemento de el y lo ponemos en el output.
- b) Por la restricción ya no podemos procesar  $N/M$  archivos al mismo tiempo, por lo que solo lo haremos con  $M/B$  archivos y resolveremos los subproblemas que quedan recursivamente. Así para permutar un archivo de tamaño  $N$  haremos lo siguiente:
1. Haremos operaciones sobre  $M/B$  archivos (las operaciones serán hechas con buffers de tamaño  $\leq B$  por lo que ocuparemos  $\leq BM/B \leq M$  memoria principal).
  2. <Mismo que en parte anterior>.
  3. Por cada archivo: lo permutamos recursivamente.
  4. <Mismo que en parte anterior>.

Así obtenemos la ecuación de recurrencia  $T(N) = mT(N/m) + \mathcal{O}(n)$  para las operaciones en memoria secundaria, cuya solución es  $\mathcal{O}(n \log_m n)$ .

“Someone is sitting in the shade today because someone planted a tree a long time ago.”  
Warren Buffett

### P3. Split y Merge en B-tree

Para resolver esta pregunta agregaremos a los nodos del B-tree su altura, lo que no tiene costo adicional en operaciones de memoria secundaria, pues estos árboles *crecen por arriba* (cuando creamos una nueva raíz su altura es igual a 1 más la altura de sus hijos).

- a) El enfoque general será hacer *merge* de dos nodos de  $T_1$  y  $T_2$  igual altura. En caso que tengan la misma altura, estos nodos serán las raíces de  $T_1$  y  $T_2$ . Por otro lado, si  $h(T_1) < h(T_2)$  los nodos serán la raíz de  $T_1/T_2$  y el hijo más izquierdo/derecho de  $T_2/T_1$  de altura  $h(T_1)/h(T_2)$ . Al hacer el *merge* de ambos nodos, si nos quedan más de  $B$  elementos en el nodo, hacemos un *split* basado en la mediana de los elementos y esta mediana sube recursivamente en el árbol, como sucede en la inserción normal de B-trees. El costo en operaciones de disco será entonces el de encontrar los nodos de igual altura  $\mathcal{O}(|h(T_1) - h(T_2)|)$  más el de posiblemente hacer *split* de la raíz del árbol más alto  $\mathcal{O}(1)$ .
- b) Primero buscamos  $x$  en el B-tree a costo  $\mathcal{O}(h(T))$ , luego convertimos al padre de la hoja donde se encuentra  $x$  en  $T_1$  y  $T_2$  respectivamente, en este momento de altura 1. Al devolvemos de la búsqueda vamos haciendo *join* de  $T_1$  con cada uno de los árboles que están a la izquierda del camino que se tomó para hacer la búsqueda de  $x$  y de  $T_2$  con los árboles que están a la derecha del camino. Finalmente, notando que se hacen  $\mathcal{O}(B)$  *join* por nivel y que los *join* se realizan entre árboles cuya diferencia de altura es a lo más 1, el costo total de este *split* será  $\mathcal{O}(B \cdot h(T))$ .

“Someone is sitting in the shade today because someone planted a tree a long time ago. ”

Warren Buffett